# Tarea 2 MLP

March 16, 2022

## 1 Tarea Multi Layer Perceptron

Por Raziel Lopez Escamilla

Importamos librerias necesarias

```
[1]: import numpy as np
     import matplotlib.pyplot as plt
     import matplotlib.image as mpimg
     %matplotlib inline
     from PIL import Image,ImageOps
     import os
     import math
     import json
     from io import StringIO
     import skimage as ski
     from skimage import data, io, filters
     from sklearn.metrics import
     →accuracy_score,classification_report,confusion_matrix
     from skimage.measure import label, regionprops, regionprops_table
     from skimage import data, filters, measure, morphology
     from sklearn.neural_network import MLPClassifier
```

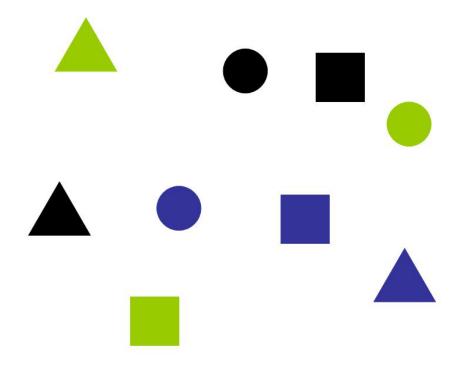
Cargamos las imagenes para entrenar y probar nuestro modelo

```
[2]: foto=os.path.join("images/foto(1).jpg")
  figuras=os.path.join("images/figuras(1).jpg")
  foto_image = Image.open(foto)
  figuras_image = Image.open(figuras)
```

La imagenen a utilizar para el entrenamiento es la siguiente.

```
[3]: figuras_image
```

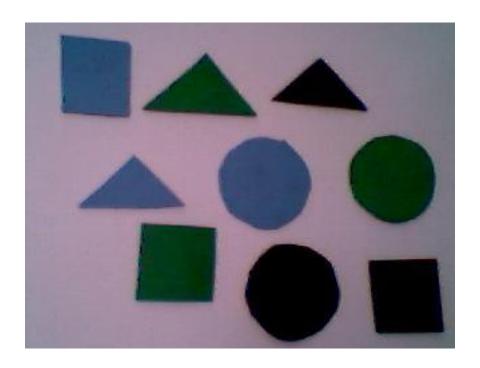
[3]:



La imagenen a utilizar para el evaluar nuestras redes neuronales es la siguiente

[4]: foto\_image

[4]:

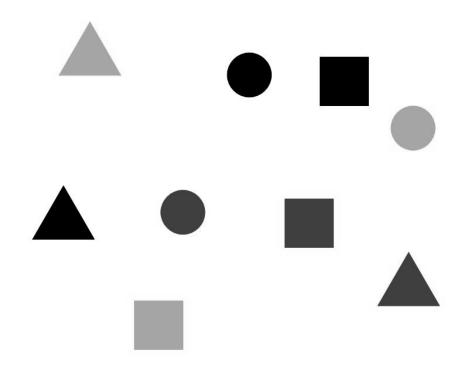


## 1.1 Clasificador de forma.

Convertimos imagenes a escala de grises para poder procesar mejor las imagenes

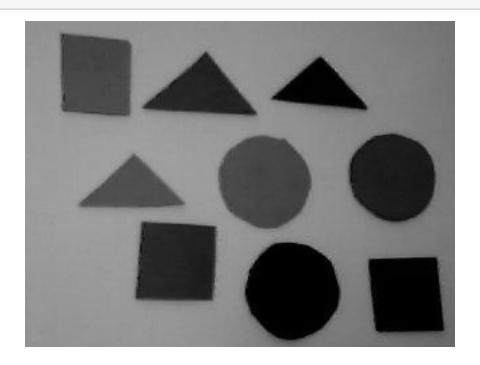
```
[5]: figuras_gray = figuras_image.convert('L')
foto_gray = foto_image.convert('L')
```

- [6]: figuras\_gray
- [6]:



# [7]: foto\_gray

[7]:



Definimos funciones que nos va a ayudar a obtener las regiones de la imagen en donde se encuentre una figura

```
[8]: def getImageRegions(img):
         img_gray = img.convert('L')
         img_array = np.array(img)
         img_gr_array = np.array(img_gray)
         #quitar componente alpha
         img_arrayRGB = np.array(img_array)[:,:,0:3]
         #invertimos valores de imagen
         img_inverted = ski.util.invert(img_gr_array)
         with np.nditer(img_inverted, op_flags=['readwrite']) as it:
             for x in it:
                 if x > 50:
                     x[...] = 255
         threshold = filters.threshold_otsu(img_inverted)
         mask = img_inverted > threshold
         mask = morphology.remove_small_objects(mask, 250)
         mask = morphology.remove_small_holes(mask, 250)
         img_labed = label(mask)
         img_regions = regionprops(img_labed)
         return img_regions
     def getPictureRegions(img):
         img_gray = img.convert('L')
         img_array = np.array(img)
         img_gr_array = np.array(img_gray)
         #quitar componente alpha
         img_arrayRGB = np.array(img_array)[:,:,0:3]
         #invertimos valores de imagen
         img_inverted = ski.util.invert(img_gr_array)
         threshold = filters.threshold_otsu(img_inverted)
         print(threshold)
         mask = img_inverted > threshold
         mask = morphology.remove_small_objects(mask, 250)
```

```
mask = morphology.remove_small_holes(mask, 250)

img_labed = label(mask)
img_regions = regionprops(img_labed)
return img_regions
```

Definimos funcion para mostrar las regiones detectadas

```
[9]: def displayRegions(img, regions):
    plt.imshow(img,cmap='gray')

    for props in regions:

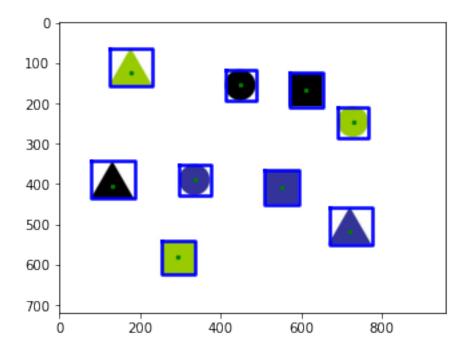
        y0, x0 = props.centroid
        orientation = props.orientation
        plt.plot(x0, y0, '.g', markersize=5)

        minr, minc, maxr, maxc = props.bbox
        margin = 0
        bx = (minc - margin , maxc + margin, maxc + margin, minc - margin, minc
        -- margin)
        by = (minr - margin, minr - margin, maxr + margin, maxr+ margin, minr -
        -- margin)
        plt.plot(bx, by, '-b', linewidth=2.5)

        plt.show()
```

Obtenenemos las regiones en la imagen de las figuras, para posteriormente etiquetarlas de forma manual, se grafican las regiones para corroborar.

```
[10]: figuras_regions = getImageRegions(figuras_image)
displayRegions(figuras_image,figuras_regions)
```



Obtenemos momentos hu de cada una de las regiones encontradas y generamos el conjunto de datos de entrenamiento.

#### 1.2 Clasificador por forma

nuestro diccionario de etiquetas para la clasifiación por forma es la siguiente:

- Cuadrado = [1,0,0]
- Circulo = [0,1,0]
- Triangulo = [0,0,1]

Ya que identificamos las regiones de interes, vamos a utilizar los momentos de hu para entrenar nuestro clasificador, cada forma identificadas fue previamente etiquetado y guardado en el archivo Train.json.

```
[11]: def getShapeData(regions, json_file):
    x = []

#Get X values
for region in regions:
    x.append(np.array(region.moments_hu))
    print("moments hu:", region.moments_hu)
    minr, minc, maxr, maxc = region.bbox

x = np.array(x)

#Get y values. For this we had to analyse the order in X values
```

```
v = []
         with open(json_file) as data_file:
             data = json.load(data_file)
         for fig in data:
            y.append(data[fig]["etiqueta_forma"])
         return x, y
[12]: |x_train, y_train = getShapeData(figuras_regions, "Train.json");
    -2.29944891e-14 -1.08749157e-12 -1.21519515e-14]
    moments hu: [ 1.59162002e-01 3.72657326e-08 8.69278990e-09 2.65069847e-12
     -4.01751430e-22 -4.23205271e-17 2.22102889e-23]
    moments hu: [0.16664305 0.
                                                         0.
                                     0.
                                               0.
                                                                   0.
     0.
               1
    moments hu: [ 1.59161459e-01 9.04516458e-08 2.77886662e-08 3.14622926e-12
      4.01320177e-22 -1.74984582e-16 8.39276933e-22]
    moments hu: [ 1.92433735e-01 8.74626685e-09 4.56078532e-03 3.92179883e-09
     -1.03035541e-15 2.33903276e-13 -1.65541995e-14]
    moments hu: [ 1.59159517e-01 1.79469796e-08 1.60670103e-09 6.19799875e-13
      1.88279009e-23 4.03088672e-17 -5.29729254e-24]
    moments hu: [0.16664305 0.
                                     0.
                                               0.
                                                         0.
                                                                   0.
     0.
               1
    moments hu: [ 1.92261785e-01 4.22874577e-08 4.53017404e-03 1.36617252e-09
      3.18816614e-15 2.52076558e-13 -1.17767323e-15]
    moments hu: [0.16664305 0.
                                     0.
                                               0.
                                                         0.
                                                                   0.
     0.
              ]
[13]: print("x train data:", x_train);
     print("y train data:", y_train);
    x train data: [[ 1.92487441e-01 4.26447426e-08 4.57024393e-03 5.28962553e-09
      -2.29944891e-14 -1.08749157e-12 -1.21519515e-14]
      [ 1.59162002e-01 3.72657326e-08 8.69278990e-09 2.65069847e-12
      -4.01751430e-22 -4.23205271e-17 2.22102889e-23]
      [ 1.66643046e-01  0.00000000e+00  0.0000000e+00  0.0000000e+00
       0.0000000e+00 0.0000000e+00 0.0000000e+00]
      [ 1.59161459e-01 9.04516458e-08 2.77886662e-08 3.14622926e-12
       4.01320177e-22 -1.74984582e-16 8.39276933e-22]
      [ 1.92433735e-01 8.74626685e-09 4.56078532e-03 3.92179883e-09
      -1.03035541e-15 2.33903276e-13 -1.65541995e-14]
      1.88279009e-23 4.03088672e-17 -5.29729254e-24]
      [ 1.66643046e-01  0.00000000e+00  0.0000000e+00  0.0000000e+00
       0.0000000e+00 0.0000000e+00 0.0000000e+00]
```

```
[ 1.92261785e-01  4.22874577e-08  4.53017404e-03  1.36617252e-09
    3.18816614e-15  2.52076558e-13 -1.17767323e-15]
[ 1.66643046e-01  0.00000000e+00  0.00000000e+00  0.00000000e+00
    0.00000000e+00  0.00000000e+00]]
y train data: [[0, 0, 1], [0, 1, 0], [1, 0, 0], [0, 1, 0], [0, 0, 1], [0, 1, 0],
[1, 0, 0], [0, 0, 1], [1, 0, 0]]
```

Creamos y ajustamos modelo

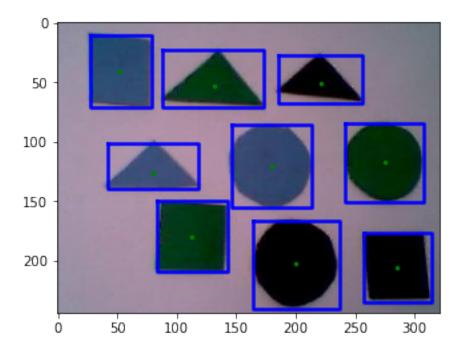
```
[15]: clf_forma.fit(x_train,y_train)
```

[15]: MLPClassifier(alpha=0.001, hidden\_layer\_sizes=(10, 3), solver='lbfgs')

Obtenemos regiones de figura para imagen de prueba.

```
[16]: foto_regions = getPictureRegions(foto_image)
displayRegions(foto_image,foto_regions)
```

166



Con la informacion obtenida generamos un JSON que nos permita etiquetar las figuras para poder entrenar nuestra red neuronal.

```
[17]: x_test, y_test = getShapeData(foto_regions, "Test.json")
    moments hu: [ 1.68621197e-01 6.20158613e-04 8.34711786e-06 2.69146925e-07
      1.83073624e-13 -3.74998103e-10 -3.59482939e-13]
    -1.60700445e-07 -1.78749246e-05 -1.30567966e-07]
    -1.23206425e-07 -1.67714297e-05 1.94444192e-07]
    moments hu: [ 1.59546922e-01 8.93004395e-05 6.25132758e-06 4.36458653e-09
     -4.02693325e-16 -2.54298778e-11 5.97993782e-16]
    -5.51420644e-17 -8.78036091e-12 3.15811359e-17]
    -1.16012064e-07 -1.78953606e-05 -1.86659165e-07]
    moments hu: [1.66265353e-01 2.21463042e-05 1.21591723e-05 2.75946081e-07
     1.51513091e-13 1.07249173e-09 4.82219277e-13]
    moments hu: [ 1.59529132e-01 5.69102066e-05 4.65125431e-06 2.51591667e-09
      3.42976006e-17 -6.01428113e-12 2.69993497e-16]
    moments hu: [ 1.67232709e-01 4.66518834e-04 5.92204579e-06 1.11376506e-07
     -4.13204286e-14 -2.21599251e-09 8.04642234e-14]
[18]: print("x test data:",x_test)
     print("y tet data:", y_train);
    x test data: [[ 1.68621197e-01 6.20158613e-04 8.34711786e-06 2.69146925e-07
       1.83073624e-13 -3.74998103e-10 -3.59482939e-13]
     [ 2.19693668e-01 1.12609527e-02 5.33069618e-03 2.00354324e-04
      -1.60700445e-07 -1.78749246e-05 -1.30567966e-07]
     [ 2.20480103e-01 1.29730008e-02 4.78587936e-03 2.22880939e-04
      -1.23206425e-07 -1.67714297e-05 1.94444192e-07]
     [ 1.59546922e-01 8.93004395e-05 6.25132758e-06 4.36458653e-09
      -4.02693325e-16 -2.54298778e-11 5.97993782e-16]
     [ 1.59448424e-01 4.65015941e-05 1.72165424e-06 1.32864007e-09
      -5.51420644e-17 -8.78036091e-12 3.15811359e-17]
     [ 2.22367759e-01 1.38235114e-02 4.70869108e-03 2.17278609e-04
      -1.16012064e-07 -1.78953606e-05 -1.86659165e-07]
     [ 1.66265353e-01 2.21463042e-05 1.21591723e-05 2.75946081e-07
       1.51513091e-13 1.07249173e-09 4.82219277e-13]
     [ 1.59529132e-01 5.69102066e-05 4.65125431e-06 2.51591667e-09
       3.42976006e-17 -6.01428113e-12 2.69993497e-16]
     [ 1.67232709e-01 4.66518834e-04 5.92204579e-06 1.11376506e-07
      -4.13204286e-14 -2.21599251e-09 8.04642234e-14]]
    y tet data: [[0, 0, 1], [0, 1, 0], [1, 0, 0], [0, 1, 0], [0, 0, 1], [0, 1, 0],
    [1, 0, 0], [0, 0, 1], [1, 0, 0]]
[19]: pred = clf_forma.predict(x_test)
     pred
```

Evaluamos desempeño de la red neuronal.

```
[20]: def ClassDetector(onehot):
          output=[]
          for caso in onehot:
              output.append(np.argmax(caso))
          return output
[21]: predclass=ClassDetector(pred)
      yclass=ClassDetector(y_test)
      print(predclass)
      print(yclass)
     [0, 2, 2, 1, 1, 2, 0, 1, 0]
     [0, 2, 2, 1, 1, 2, 1, 2, 0]
[22]: print(accuracy_score(predclass,yclass))
     0.7777777777778
[23]: print(confusion_matrix(predclass,yclass))
     [[2 1 0]
      [0 2 1]
      [0 0 3]]
```

## 1.3 Clasificador por color

nuestro diccionario de etiquetas para la clasifiación por color es la siguiente:

Verde = [1,0,0]
Negro = [0,1,0]
Azul = [0,0,1]

Ya que identificamos las regiones de interes, con ayuda de la coordenada del centroide vamos a obtener el color de cada figura, estos valores los vamos a utilizar para entrenar nuestro MLP, cada color identificado de las figuras fue previamente etiquetado y guardado en el archivo Train.json

```
[90]: def getColorData(regions, json_file, img):
          x = []
          #Get X values
          for reg in regions:
              y0, x0 = reg.centroid
              color = np.array(img)[int(y0),int(x0),0:3]
              print("centroide: ", reg.centroid, "color:", color)
             x.append(color)
          x = np.array(x)
          #Get y values. For this we had to analyse the order in X values
          y = []
          with open(json_file) as data_file:
              data = json.load(data_file)
          for fig in data:
              y.append(data[fig]["etiqueta_color"])
          return x, y
     x_train, y_train = getColorData(figuras_regions, "Train.json", figuras_image)
     centroide: (125.65209471766849, 177.20441206233556) color: [152 203
                                                                            07
     centroide: (155.57791225416037, 449.2515668899935) color: [0 0 0]
     centroide: (166.5, 611.5) color: [0 0 0]
     centroide: (246.25313117996046, 729.0129641836959) color: [152 203
                                                                           07
     centroide: (405.3281188118812, 131.85108910891088) color: [0 0 0]
     centroide: (389.90907122753845, 335.85516345529334) color: [52 51 153]
     centroide: (408.5, 551.5) color: [ 52 51 153]
     centroide: (519.1927379784102, 721.4995093228656) color: [ 52 51 153]
     centroide: (582.5, 294.5) color: [152 203
[91]: print("x train data:", x_train);
      print("y train data:", y_train);
     x train data: [[152 203
                               0]
      Γ 0
           0
                 07
      [ 0
             0
                 0]
      [152 203
                 01
      Γ 0
                 0]
            0
      [ 52 51 153]
      [ 52 51 153]
      [ 52 51 153]
      [152 203
     y train data: [[1, 0, 0], [0, 1, 0], [0, 1, 0], [1, 0, 0], [0, 1, 0], [0, 0, 1],
     [0, 0, 1], [0, 0, 1], [1, 0, 0]]
```

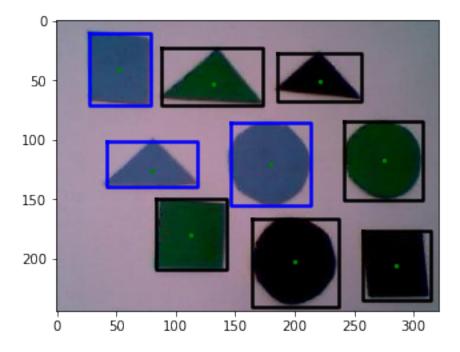
Creamos y ajustamos modelo

```
[92]: clf_color = MLPClassifier(solver='lbfgs', alpha=1e-3,
                       hidden_layer_sizes=(10,3))
[93]: clf_color.fit(x_train,y_train)
[93]: MLPClassifier(alpha=0.001, hidden_layer_sizes=(10, 3), solver='lbfgs')
[94]: x_test, y_test = getColorData(foto_regions, "Test.json", foto_image)
     centroide:
                 (40.117914625612315, 52.42477256822953) color: [ 43 77 114]
                 (52.94328358208955, 131.97611940298506) color: [ 1 60 16]
     centroide:
     centroide: (50.16792323509253, 220.76285126799178) color: [1 1 0]
     centroide: (116.79842473745624, 275.0399649941657) color: [ 0 40 4]
     centroide: (119.94977678571429, 179.27650669642858) color: [51 70 110]
     centroide: (125.41231593038822, 80.2764390896921) color: [ 62 81 123]
     centroide: (180.04770642201834, 112.97094801223241) color: [ 0 56 17]
     centroide: (201.72028313400048, 199.81401025140346) color: [0 0 0]
     centroide: (205.18242565987305, 285.1620447711326) color: [0 0 0]
[95]: print("x test data:", x test);
      print("y test data:", y_test);
     x test data: [[ 43 77 114]
      [ 1 60 16]
      1
             1
                 0]
      Γ 0 40
                 41
      [ 51 70 110]
      [ 62 81 123]
      [ 0 56 17]
      [ 0
                 0]
             0
                 0]]
     y test data: [[0, 0, 1], [1, 0, 0], [0, 1, 0], [1, 0, 0], [0, 0, 1], [0, 0, 1],
     [1, 0, 0], [0, 1, 0], [0, 1, 0]]
[96]: pred2 = clf color.predict(x test)
      pred2
[96]: array([[0, 0, 1],
             [0, 1, 0],
             [0, 1, 0],
             [0, 1, 0],
             [0, 0, 1],
             [0, 0, 1],
             [0, 1, 0],
             [0, 1, 0],
             [0, 1, 0]])
```

Evaluamos desempeño de la red neuronal.

```
[97]: predclass=ClassDetector(pred2)
       yclass=ClassDetector(y_test)
       print(predclass)
       print(yclass)
      [2, 1, 1, 1, 2, 2, 1, 1, 1]
      [2, 0, 1, 0, 2, 2, 0, 1, 1]
[98]: print(accuracy_score(predclass,yclass))
      0.66666666666666
[99]: print(confusion_matrix(predclass,yclass))
      [0 0 0]]
       [3 3 0]
       [0 0 3]]
[100]: def getColorName(classification):
           color = '-m'
           if classification == 0:
               color = '-g'
           if classification == 1:
               color = '-k'
           if classification == 2:
               color = '-b'
           return color
       def showColorResults(img,regions, predclass):
           plt.imshow(img)
           indx = 0
           for r in regions:
               y0, x0 = r.centroid
               orientation = r.orientation
               plt.plot(x0, y0, '.g', markersize=5)
               minr, minc, maxr, maxc = r.bbox
               margin = 0
               bx = (minc - margin , maxc + margin, maxc + margin, minc - margin, minc ⊔
        → margin)
               by = (minr - margin, minr - margin, maxr + margin, maxr+ margin, minr -
        →margin)
               color = getColorName(predclass[indx])
               plt.plot(bx, by, color , linewidth=2.5)
               indx += 1
```

```
plt.show()
showColorResults(foto_image,foto_regions,predclass)
```



Con esos 2 clasificadores al unir ambas salidas podemos generar un dato que nos indique un color y forma para alguna entrada

```
[101]: print("Predicciones individuales:\n")
    print("Prediccion en forma:\n",pred)
    print("Prediccion en color:\n",pred2)
```

### Predicciones individuales:

```
Prediccion en forma:
```

[[1 0 0]

[0 0 1]

[0 0 1]

[0 1 0]

[0 1 0]

[0 0 1]

[1 0 0]

[0 1 0]

[1 0 0]]

Prediccion en color:

[[0 0 1]

```
[0 1 0]

[0 1 0]

[0 1 0]

[0 0 1]

[0 0 1]

[0 1 0]

[0 1 0]

[0 1 0]]

[110]: output = []

for i in range(len(pred)):
```

output.append(np.concatenate((pred[i], pred2[i])))

print("Prediccion conjunta:\n",np.array(output))

#### Prediccion conjunta:

#### 1.4 Conclusiones

Se pudo entrenar dos perceptrones multicapa, uno para clasificar por forma y otro por color, los resultados obtenidos NO fueron 100% precisos, es posible que esto se deba a diversos factores como el conjunto de datos de entrenamiento, la arquitectura de las redes y el número máximo de epocas, durante el desarrollo de la tarea notamos que la presición de los modelos variaba, esto se debe a la inicializacion de los pesos con valores aleatorios, entonces abra ocaciones en las que el modelo tenga una presición mayor al 60% y en otras tenga un porcentaje menor. En este caso, para poder lograr entrenar las redes neuronales es necesario tener conocimientos de vision por computadora, esto ayuda al momento de la extracción de características de los conjuntos de entrenamiento y de prueba.

```
[]:
```